import

```
In [1]: import pandas as pd
        import matplotlib.pyplot as plt
        import numpy as np
        import time
        from sklearn import externals
        from sklearn.metrics import accuracy_score
        from sklearn.linear_model import LinearRegression, SGDRegressor, Lasso, Ridge, ElasticNet
        from sklearn.ensemble import GradientBoostingRegressor, BaggingRegressor, RandomForestRegressor, ExtraTreesRegressor, AdaBoostRegressor
        from sklearn.model_selection import train_test_split, cross_val_score
        import pickle
        import lime
        import lime.lime_tabular
        from yellowbrick.regressor import ResidualsPlot
        from fancyimpute import SoftImpute
        import warnings
        warnings.filterwarnings('ignore')
```

Using TensorFlow backend.

functions & var


datasets

Questão 1

Mostre graficamente a evolução da taxa de fertilidade e do Produto Interno Bruto na União Européia.

Resposta:

```
In [4]: # GDP (current US$)
        # https://data.worldbank.org/indicator/NY.GDP.MKTP.CD
        pib_cod = 'NY.GDP.MKTP.CD'
        pib nome = 'GDP (current US$)'
        # Fertility rate, total (births per woman)
        # https://data.worldbank.org/indicator/SP.DYN.TFRT.IN
        fertilidade_cod = 'SP.DYN.TFRT.IN'
        fertilidade_nome = 'Fertility rate, total (births per woman)'
        # Filtro para UE
        df_grafico = eu[eu['CountryName']=='European Union']
        # Dados para gráfico
        data1 = df_grafico[df_grafico['IndicatorCode']==pib_cod]['Value'].values
        data1_year = df_grafico[df_grafico['IndicatorCode']==pib_cod]['Year'].values
        data2 = df_grafico[df_grafico['IndicatorCode']==fertilidade_cod]['Value'].values
        data2_year = df_grafico[df_grafico['IndicatorCode']==fertilidade_cod]['Year'].values
        fig, ax1 = plt.subplots()
        color = 'tab:blue'
        ax1.set_xlabel('Year')
        ax1.set_ylabel(pib_nome, color=color)
        ax1.plot(data1_year, data1, color=color)
        ax1.tick_params(axis='y', labelcolor=color)
        ax2 = ax1.twinx()
        color = 'tab:red'
        ax2.set_ylabel(fertilidade_nome, color=color)
        ax2.plot(data2_year, data2, color=color)
        ax2.tick_params(axis='y', labelcolor=color)
        fig.tight_layout()
        plt.show()
```



Questão 2

Podemos afirmar que existe uma correlação entre a taxa de fertilidade e do Produto Interno Bruto na União Européia? Explique.

Resposta:

Sim, existe uma correlação, mas é negativa. A taxa de fertilidade da UE é inversamente proporcional ao PIB, ou seja, quanto maior é o PIB menor é a taxa.

```
In [5]: # Anos com valores
# df_grafico[df_grafico['IndicatorCode'].isin([fertilidade_cod,pib_cod])].groupby('Year').count()


In [6]: df_lr = df_grafico[df_grafico['Year']<2014]


x = df_lr[df_lr['IndicatorCode']==fertilidade_cod]['Value'].values
y = df_lr[df_lr['IndicatorCode']==pib_cod]['Value'].values

fit = np.polyfit(x,y,1)
    fit_fn = np.polyfd(fit)

plt.title(fertilidade_nome[:14]+'... vs '+pib_nome)
plt.xlabel(pib_nome)
plt.ylabel(fertilidade_nome)

plt.plot(x,y, 'yo', x, fit_fn(x), '--k')
print('Correlação de Pearson: ',np.corrcoef(x,y)[1][0])</pre>
```





Questão 3

Podemos afirmar com as informações das questões anteriores que "o crescimento do PIB levou a uma redução da taxa de fertilidade na União Européia"?. Explique.

Resposta:

Correlação não implica causa!

Pouco provável, não podemos concluir que a resposta para a redução é só o PIB. Precisamos utilizar mais variáveis para tentar responder esse evento de redução, pois ele é complexo e sabemos que existem muitas variáveis envolvidas. Seria interessante utilizar modelos de machine learning ou deep learning para tentar responder esse evento com mais precisão.

Questão 4

Consumo, segundo Keynes (https://en.wikipedia.org/wiki/John Maynard Keynes) (economista inglês), é uma função linear de um componente

autônomo invariável que é independente da renda disponível (a) e da proporção da renda alocada para consumo (b) multiplicada pela renda (Y), conforme abaixo:

$$C = a + b * Y$$

O parâmetro b é conhecido como a propensão marginal a consumir, ou seja, o crescimento no consumo decorrente de um aumento na renda disponível.

Faça a regressão da equação acima por Mínimos Quadrados Ordinários utilizando Household final consumption expenditure (constant 2005 US\$) como proxy para o consumo, o GDP at market prices (constant 2005 US\$) como proxy para a renda disponível utilizando os dados de cada um dos países membros da União Européia. Podemos rejeitar a hipótese de que o parâmetro b é igual a zero? Comente.

Resposta:

Sim, podemos. O consumo de fato subiu durante o crescimento da renda.

O modelo de regressão linear apresentou R² de 0.99, assim indicando forte relação entre as variáveis utilizadas. A distribuição de erros é uma curva normal e as variáveis apresentam relação linear, esses são pré-requisitos fundamentais para um modelo linear. Seguem as evidências:

Preparando Dataset

```
In [7]: # Conversão do dataset
var_x = 'Household final consumption expenditure (constant 2005 US$)'
var_y = 'GDP at market prices (constant 2005 US$)'
df_mqo = eu[(-eu['CountryName'].isin(['European Union'])) & eu['IndicatorName'].isin([var_x,var_y])]

anos = df_mqo['Year'].unique()
paises = df_mqo['CountryName'].unique()
lista = [(x, y) for x in anos for y in paises]


df_mqo_v2 = pd.DataFrame(columns=['Year', 'CountryName',var_x,var_y],dtype=np.float)

df_mqo_v2['Year'] = np.asarray([ano for ano,pais in lista])
df_mqo_v2['CountryName'] = np.asarray([pais for ano,pais in lista])

for index, row in df_mqo.iterrows():
    if row['IndicatorName'] == var_x:
        df_mqo_v2.loc[(df_mqo_v2['Year'] == row['Year']) & (df_mqo_v2['CountryName'] == row['CountryName']), var_x] = row['Value']
    else:
        df_mqo_v2.loc[(df_mqo_v2['Year'] == row['Year']) & (df_mqo_v2['CountryName'] == row['CountryName']), var_y] = row['Value']
```

Modelo Linear - Resultados

```
In [8]: # Faz cópia de dataset
        df_mqo_v3 = df_mqo_v2.dropna().copy()
        # Converte variáveis categóricas
        df_mqo_v3 = fnc_Dummies(df=df_mqo_v3)
        # Variáveis para treino
        feature_names = ['Year', 'CountryName', var_x]
        target_name = var_y
        X = df_mqo_v3[feature_names]
        y = df_mqo_v3[target_name]
        # Separa dados para treino e teste
        X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2)
        # Prepara modelo para gráfico
        model = LinearRegression()
        visualizer = ResidualsPlot(model)
        visualizer.fit(X_train, y_train)
        visualizer.score(X_test, y_test)
        visualizer.poof()
```



Correlação

```
In [9]: x = df_mqo_v3[var_x].values
y = df_mqo_v3[var_y].values


fit = np.polyfit(x,y,1)
fit_fn = np.poly1d(fit)

plt.title('Regressão linear')
plt.xlabel(var_x)
plt.ylabel(var_y)

plt.plot(x,y, 'yo', x, fit_fn(x), '--k')

print('Correlação de Pearson: ',np.corrcoef(x,y)[1][0])
```

Correlação de Pearson: 0.997676685154029



Questão 5

Utilizando todas variáveis disponíveis na base de dados, construa o melhor modelo para explicar a taxa de fertilidade com até 5 variáveis.

Resposta:

Data preparation & Missing Values

```
In [10]: # Cópia de dataframe
    df_new = eu[(-eu['CountryName'].isin(['European Union']))]
    df_new.Year.astype('category')

# Pivot table para Indicadores
    df_new_v2 = pd.pivot_table(df_new, values='Value', index=['Year','CountryName'], columns='IndicatorName')
    df_new_v2.insert(loc=0, column='CountryName', value=df_new_v2.index.get_level_values('CountryName'))
    df_new_v2.insert(loc=0, column='Year', value=df_new_v2.index.get_level_values('Year'))

# Converte variáveis categóricas
    df_new_v2 = fnc_Dummies(df=df_new_v2)
```

```
In []: # Elimina features com menos de 30% de dados
df = df_new_v2.copy()
df_new_v3 = df[[column for column in df if df[column].count() / len(df) >= 0.3]]
print("Lista de fatos excluídos:\n\n Total excluído:", round(len(df_new_v3.columns)/len(df.columns),2)*100,'%\n\n', end=" ")

for c in df.columns:
    if c not in df_new_v3.columns:
        print(c, end="\n ")

# Missing Values
df_new_v3 = fnc_Imputer(df_new_v2)
```

In [12]: # Matriz de Correlação da Fertilidade
 df_corr = df_new_v3.corr()
 df_corr[[fertilidade_nome]].sort_values(by=fertilidade_nome,ascending=False)

Out[12]:

27/01/2019

	Fertility rate, total (births per woman)	
Fertility rate, total (births per woman)	1.000000	
Birth rate, crude (per 1,000 people)	0.949686	
Age dependency ratio, young (% of working-age population)	0.852223	
Population, ages 0-14 (%of total)	0.845400	
Age dependency ratio (%of working-age population)	0.737768	
Urban population growth (annual %)	0.489621	
Mortality rate, adult, female (per 1,000 female adults)	0.467726	
Mortality rate, infant (per 1,000 live births)	0.466446	
Mortality rate, under-5 (per 1,000)	0.465638	
Adolescent fertility rate (births per 1,000 women ages 15-19)	0.400526	
Population, female (% of total)	0.393750	
Rural population (%of total population)	0.391737	
Life expectancy at birth, male (years)	0.389749	
Life expectancy at birth, total (years)	0.383373	
Population growth (annual %)	0.380989	
Life expectancy at birth, female (years)	0.375188	
Survival to age 65, female (%of cohort)	0.363533	
Number of under-five deaths	0.360481	
Number of infant deaths	0.359097	
Survival to age 65, male (%of cohort)	0.315776	
Death rate, crude (per 1,000 people)	0.267121	
Agricultural raw materials imports (% of merchandise imports)	0.261226	
Merchandise imports from developing economies in Sub-Saharan Africa (%of total merchandise imports	0.260621	
Merchandise exports to developing economies in Sub-Saharan Africa (% of total merchandise exports)	0.252337	
Mortality rate, adult, male (per 1,000 male adults)	0.245531	
Merchandise exports by the reporting economy, residual (% of total merchandise exports)	0.244817	
Merchandise imports by the reporting economy, residual (% of total merchandise imports)	0.231759	
Population, ages 15-64 (% of total)	0.224319	
CO2 emissions from manufacturing industries and construction (% of total fuel combustion)	0.221011	
CO2 emissions from residential buildings and commercial and public services (% of total fuel combustion	0.213546	
<u> </u>	-0.491713	
···	-0.491713 -0.492392	

maikon-abati

r	maikon-abati				
	Fertility rate, total (births per woman)				
Bank capital to assets ratio (%)	-0.500658				
Immunization, measles (% of children ages 12-23 months)	-0.501781				
Labor force, female (% of total labor force)	-0.502054				
Ease of doing business index (1=most business-friendly regulations)	-0.503063				
Immunization, DPT (% of children ages 12-23 months)	-0.504797				
Time to resolve insolvency (years)	-0.518458				
Lifetime risk of maternal death (1 in: rate varies by country)	-0.542568				
Improved sanitation facilities, rural (% of rural population with access)	-0.601791				
Improved sanitation facilities (% of population with access)	-0.609923				
Improved sanitation facilities, urban (% of urban population with access)	-0.612721				
Improved water source, rural (% of rural population with access)	-0.616532				
Improved water source (% of population with access)	-0.618691				
Improved water source, urban (% of urban population with access)	-0.619488				
Year	-0.704792				
Commitments, IDA (COM, current US\$)	NaN				
Currency composition of PPG debt, SDR (%)	NaN				
Debt forgiveness grants (current US\$)	NaN				
EBRD, private nonguaranteed (NFL, current US\$)	NaN				
IDA grants (current US\$)	NaN				
Net financial flows, IDA (NFL, current US\$)	NaN				
Net financial flows, IMF concessional (NFL, current US\$)	NaN				
PPG, IDA (AMT, current US\$)	NaN				
PPG, IDA (DIS, current US\$)	NaN				
PPG, IDA (DOD, current US\$)	NaN				
PPG, IDA (INT, current US\$)	NaN				
PPG, IDA (NTR, current US\$)	NaN				
PPG, IDA (TDS, current US\$)	NaN				

1286 rows × 1 columns

```
In [13]: # Variável de interesse
         var_interesse = fertilidade_nome
         # Escopo de treino/test
         colunas = list(df new v3.columns)
         colunas.remove(fertilidade nome)
         feature_names = colunas
         target_name = var_interesse
         X = df_new_v3[feature_names]
         y = df_new_v3[target_name]
         # Separa dados para treino e teste
         X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2)
         # Lista de resultados
         resultados = [['status','var','model','mean','std','time','scores','caminho']]
         # Score dos modelos
         print('='*100)
         print(var_interesse)
         print('='*100)
         Y = df_new_v3[[var_interesse]].values.ravel()
         for var in modelos:
             start = time.time()
             try:
                 filename = str('../../models/'+var.__name__+'.model')
                 print(var)
                 clf = var()
                 # Calcula o score
                 scores = cross_val_score(clf, df_new_v3, Y, cv=10, error_score='raise')
                 print('Mean score: ',np.mean(scores), '/ Std Score: ',np.std(scores))
                 resultados.append(['ok',var_interesse,var.__name__,np.mean(scores),np.std(scores),time.time() - start,scores,filename])
                 # Salva modelo
                 model = clf.fit(X_train, y_train)
                 externals.joblib.dump(model,filename)
             except(Exception):
                 print('>> Validar parâmetros.')
                 resultados.append(['erro',var_interesse,var.__name__,None,None,time.time() - start,None,None])
             finally:
                 print('-'*100)
```

27/01/2019

```
______
     Fertility rate, total (births per woman)
     ______
     <class 'sklearn.ensemble.gradient boosting.GradientBoostingRegressor'>
     Mean score: 0.9498657118073565 / Std Score: 0.1376871684155691
     ______
     <class 'sklearn.ensemble.bagging.BaggingRegressor'>
     Mean score: 0.958153173047309 / Std Score: 0.11060923252366513
     ______
     <class 'sklearn.ensemble.forest.RandomForestRegressor'>
     Mean score: 0.9426215306778645 / Std Score: 0.1504299415825261
     ------
     <class 'sklearn.ensemble.forest.ExtraTreesRegressor'>
     Mean score: 0.9433292175633525 / Std Score: 0.10748931348624972
     ______
     <class 'sklearn.ensemble.weight_boosting.AdaBoostRegressor'>
     Mean score: 0.9418747789470107 / Std Score: 0.07399990967872937
     ______
     <class 'sklearn.linear model.stochastic gradient.SGDRegressor'>
     Mean score: -2.4123377050424653e+71 / Std Score: 3.273163204464693e+71
     <class 'sklearn.linear_model.coordinate_descent.Lasso'>
     Mean score: -4051.464182044576 / Std Score: 12075.168106369343
     ______
     <class 'sklearn.linear_model.ridge.Ridge'>
     Mean score: -603402718197.5461 / Std Score: 1398275131351.2979
     ______
     <class 'sklearn.linear model.coordinate descent.ElasticNet'>
     Mean score: -790.4387726538359 / Std Score: 2298.147954062192
     ______
     <class 'sklearn.linear model.base.LinearRegression'>
     Mean score: -294088734216.0228 / Std Score: 588229160126.1681
     ______
In [14]: # Salva planilhas com score de modelos
     writer = pd.ExcelWriter('.../../dist/resultados_modelos.xlsx', engine='xlsxwriter')
     df_final = pd.DataFrame(resultados[1:])
     df final.columns = resultados[0]
```

```
df_final.to_excel(writer, sheet_name='Sheet1', index=False)
writer.save()
```

In [15]: df_final.sort_values(by=['mean'], ascending=False)

Out[15]:

Г	status	var	model	mean	std	time	scores	caminho
1	ok	Fertility rate, total (births per woman)	BaggingRegressor	9.581532e-01	1.106092e-01	50.583918	[0.9638536535659511, 0.9975196663418858, 0.998	//models/BaggingRegressor.model
0	ok	Fertility rate, total (births per woman)	GradientBoostingRegressor	9.498657e-01	1.376872e-01	131.870818	[0.9668257313948193, 0.9982827521245184, 0.998	//models/GradientBoostingRegressor.model
3	ok	Fertility rate, total (births per woman)	ExtraTreesRegressor	9.433292e-01	1.074893e-01	19.065458	[0.8734091736600261, 0.9831857764887317, 0.990	//models/ExtraTreesRegressor.model
2	ok	Fertility rate, total (births per woman)	RandomForestRegressor	9.426215e-01	1.504299e-01	47.736675	[0.9450056586169125, 0.9971917988056322, 0.996	//models/RandomForestRegressor.model
4	ok	Fertility rate, total (births per woman)	AdaBoostRegressor	9.418748e-01	7.399991e-02	114.062698	[0.932219056841623, 0.98965140411541, 0.982667	//models/AdaBoostRegressor.model
8	ok	Fertility rate, total (births per woman)	ElasticNet	-7.904388e+02	2.298148e+03	14.034799	[0.06096002684390356, 0.4556464086168164, 0.62	//models/ElasticNet.model
6	ok	Fertility rate, total (births per woman)	Lasso	-4.051464e+03	1.207517e+04	11.567414	[-0.2230657803450975, 0.2322276941487278, 0.46	//models/Lasso.model
9	ok	Fertility rate, total (births per woman)	LinearRegression	-2.940887e+11	5.882292e+11	8.799115	[0.6980346972624497, 0.7569493032095755, -1736	//models/LinearRegression.model
7	ok	Fertility rate, total (births per woman)	Ridge	-6.034027e+11	1.398275e+12	11.631908	[0.4480556037313639, 0.6063387959622368, -2486	//models/Ridge.model
5	ok	Fertility rate, total (births per woman)	SGDRegressor	-2.412338e+71	3.273163e+71	0.342238	[-9.748696307358854e+69, -1.1831318055192161e+	//models/SGDRegressor.model

('0.04 < Health expenditure, public (% of government expenditure) <= 1.48',

```
In [21]: # Define seed para modelo
           def explain(instance, predict_fn, **kwargs):
             np.random.seed(16)
             return explainer.explain instance(instance, predict fn, **kwargs)
          # Modelo de predição para teste
          i = 302
          exp = explain(X_test.values[i], model.predict, num_features=5)
          Intercept 1.6969907389449366
          Prediction_local [1.98394275]
          Right: 1.9475947385082149
In [22]: # Resultados para 5 features
          exp.show_in_notebook(show_table=True)
                                                                              positive
                                                     negative
                                                                                                                                                     Value
                                                                                               Feature
             Predicted value
                                                                      12.70 < Birth rate, crud...
            0.34
                                        3.42
                                                                                               Birth rate, crude (per 1,000 people)
                                                                                                                                                     13.30
                                                                        0.14
                                                                      Age dependency ratio ...
           (min)
                                        (max)
                          1.95
                                                                                                                                                    57.94
                                                                                               Age dependency ratio (% of working-age population)
                                                                       0.10
                                                 0.05 < Electricity produ.
                                                                                               Electricity production from hydroelectric sources (% of total) 0.42
                                                                      Mortality rate, under-5 ...
                                                                                               Mortality rate, under-5 (per 1,000)
                                                                                                                                                    20.80
                                                                      0.04 < Health expenditur...
                                                                                               Health expenditure, public (% of government expenditure)
                                                                                                                                                   0.72
```

0.04919169186857802)]